


LLM Gateway 보안 평가 프레임워크

v2 — 5개 위협 × 8+ 엔진 × 2+ Gateway × 3단계 검증 × 2언어


1. 핵심 구조: Gateway → Guardrail 엔진 호출 관계

Gateway가 상위, Guardrail 엔진은 Gateway가 호출하는 하위 컴포넌트



2. 3단계 검증 방법론

모든 위협 × 모든 엔진에 동일하게 적용하는 검증 절차



3. 위협 × Guardrail 엔진 매트릭스

5개 위협에 대해 어떤 엔진을 검증하는지 — ☒ 완료 / ☐ 예정

위협 \ 엔진	Presidio	LLM Guard	Lakera	NeMo	Llama Guard	ContentFilter	자체구현
1. PII 유출	☒	☐	☐	☐	☐	☐	☐
2. 인젝션	☐	☐	☐	☐	☐	☐	☐
3. 유해성	☐	☐	☐	☐	☐	☐	☐
4. 할루시네이션	☐	☐	☐	☐	☐	☐	☐
5. 공급망 보안	☐	☐	☐	☐	☐	☐	☐

☒ 완료 ☐ 예정 ☐ 해당없음 × Gateway 2+개 × 한국어/영어 = 전체 매트릭스

4. 퍼징 도구 모듈 구조 (v2)

위협별 특화 모듈 + Gateway 비종속 HTTP 디스패처

